

Metody i Modele Eksploracyjnej Analizy Danych

Projekt

Michał Mikołajczyk, Jakub Misztela

15.05.2026

Business Understanding

W projekcie zajęto się problemem wysokości napiwków otrzymywanych przez dostawców jedzenia. Napiwek jest w tym sensie ciekawym problemem, że można by spodziewać się, że nie będzie łatwo dokonać jego predykcji na podstawie modelu statystycznego, spodziewając się, że zależy to głównie od czynników psychologicznych i charakteru zarówno kuriera, jak i klienta. Postanowiono więc zobaczyć, jak dużo można jednak zamodelować.

W projekcie postawiono za cel znalezienie zależności, od których zależy wysokość napiwku i zbudowanie modelu predykcyjnego. Podstawowym kryterium sukcesu jest osiągnięcie akceptowalnego błędu predykcji. Co ważne, postanowiono nie uwzględniać sytuacji, w których nie było napiwku. Decyzja klienta, czy przyznać napiwek, rządzi się innymi zależnościami niż ustalenie wysokości napiwku. Starano się uzyskać potwierdzenie mna takie pytania, jak: Czy klienci są hojniejsi po godzinach pracy? Czy długość dostawy wpływa negatywnie czy pozytywnie na napiwek? Jak wysokość napiwku zależy od dnia tygodnia? Model ma swoje ograniczenia, które nie pozwolą dowolnie ekstrapolować jego przewidywań – modelowany jest obszar miasta Santa Barbara w Stanach Zjednoczonych, na podstawie danych z aplikacji Uber Eats. Nie uwzględniono ważnych czynników, jak rodzaj i typ restauracji, pogoda czy sytuacja ekonomiczna.

Data Understanding

Do modelowania wykorzystano bazę **Uber Delivery Tips Dataset** <https://www.kaggle.com/datasets/green7ea/uber-delivery-tips-dataset-real-world-data> z serwisu Kaggle. Jest to średniej wielkości zbiór danych – 1214 obserwacji. Po usunięciu obserwacji z zerowym napiwkiem zostało ich 1146. Dane były zbierane od marca do października roku 2025.

Poszczególne obserwacje reprezentują jedną dostawę. Baza nie ma brakujących danych, ale usunięto niektóre zmienne, a poniżej przedstawiono pozostawione:

➤ Zmienna objaśniana

- ♦ **tip** – wysokość napiwku,

➤ Data

- ♦ **date** – data w formacie YYYY-MM-DD,
- ♦ **time** – godzina dostawy, z przedziału [0; 23,5],
- ♦ **weekday** – dzień tygodnia, z przedziału [0; 6],

➤ Zmienne geograficzne

- ♦ **distance** - odległość restauracji od adresu dostawy, w milach,

- ♦ **dropoff_longitude, dropoff_latitude** – współrzędne adresu dostawy,
- ♦ **restaurant_longitude, restaurant_latitude** – współrzędne restauracji,

➤ Dotyczące dostawy

- ♦ **duration_min** – czas dostawy w minutach,
- ♦ **points** – liczba punktów, które odwiedza dostawca na trasie,
- ♦ **deliveries_count** – liczba zamówień w danym adresie,
- ♦ **fare** – koszt dostawy.

Data Preparation

Nie wykonywano normalizacji, bo nie jest ona potrzebna przy regresji wielokrotnej. Postanowiono wykonać transformacje kilku zmiennych, aby poszukać ukrytych informacji:

- ♦ **month** – miesiąc roku, z przedziału [0; 11]. Chociaż dane nie były zbierane we wszystkich miesiącach, można się spodziewać zależności, że wraz z corocznymi wahaniami temperatury wysokość napiwka będzie się zmieniać,
- ♦ **geo_distance** – odległość między restauracją a adresem dostawy. Nie jest to zmienna tożsama z **distance**, ponieważ jedna to odległość bezwzględna, a druga to droga zrobiona przez dostawcę.

screen z R albo wzorek

- ♦ **speed** – $\text{distance} / \text{duration_min}$
- ♦ **geo_speed** – $\text{geo_distance} / \text{duration_min}$


W tak przygotowanej bazie najpierw postanowiono najpierw zrobić korelogram zmiennej objaśnianej z **distance, geo_distance, duration_min, fare, geo_spped** i **speed**, ponieważ spodziewano się tam zależności liniowych.

Podczas przeglądania korelogramu natrafiono na outlier w zmiennej **geo_distance**. Po analizie okazało się, że pochodzi on z odstającej wartości w **dropoff_latitude**. Najprawdopodobniej była to literówka osoby tworzącej bazę danych, bo wartość różniła się o stopień od wartości tej zmiennej dla innych obserwacji. Zaimputowaną więc do bazy danych powiększoną o stopień zmienną. Sytuację tę przedstawiono na box plot na kolejnej stronie:


Histogramy zmiennych wskazują, że wszystkie z nich są prawoskośne. Przez to, że nie są to rozkłady liniowe, nie można ufać testowi p-value. Spróbowano zlogarytmować zmienne, ale dało to efekt w postaci bardziej zbliżonego do normalnego rozkładu tylko w przypadku **log_tip** i **log_distance**. Rozkład **log_geo_distance** otrzymał dwa wierzchołki, a jego korelacja ze zmienną objaśnianą zmniejszyła się. Rozkład pozostałych zmiennych nie poprawił się, a ich korelacje pozostały słabe.

Ogólnie, korelacje zmiennych objaśniających i objaśnianej **tip** są słabe. Najmocniejsza jest **duration_min** i skorelowane ze sobą odległości **distance** i **geo_distance**. Wskazuje to na to, że odbiorcy nie uwzględniają zwykle kosztu dostawy i prędkości, z jaką jechał dostawca w ustaleniu wysokości napiwku. Fakt, że **geo_distance** ma słabszą korelację niż odległość, jaką przebył dostawca może sugerować, że odbiorcy znają czas dojazdu do restauracji, z której zamawiają jedzenie i nie posługują się miarą geograficzną, która nie oddaje czasu i drogi potrzebnej aby do niej dojechać. Podobna sytuacja występuje z **geo_speed**.


W celu ograniczenia liczby zmiennych i przedziwziałaniu dużej korelacji w objaśniających **log_distance** i **duration_min** wprowadzono nową zmienną **dist_dur** jako iloczyn tych dwóch i okazało się, że jej korelacja jest odrobinę lepsza – więc zostawiono ją do testów.




Pozostałe zmienne, jak widać po korelogramie nie mają żadnego widocznego wpływu na zmienną objaśnianą:



Zmienna **deliveries_count** przyjmowała trzy wartości, więc zastosowano one-hot encoding, zmieniając typ danej na faktor. Uznano, że różnica pomiędzy jednym, a dwoma zamówieniami może być inna, niż różnica między dwoma a trzema:




Zrobiono także dodatkowy korelogram korelacji Spearmana, chcąc oszacować zależności między zmiennymi, które nie mają rozkładów normalnych:




Zobaczywszy, że istnieje pewna korelacja między **points** a **deliveries_count** dodano nową zmienną **poin_deli** jako iloczyn tych dwóch. Z korelogramu Można wywnioskować, że często występuje korelacja między wysokością napiwku, a liczbą zamówień, a także, że występuje dość duża korelacja między liczbą zamówień pod jednym adresem, a całkowitą liczbą adresów, jakie odwiedza dostawca **points**. W trakcie modelowania ocenione będą różne kombinacje tych zmiennych na zbiorze walidacyjnym.

Jako ostatnie przeanalizowano zmienne związane z czasem. Można się spodziewać, że napiwek będzie większy, gdy pora dnia i roku będzie sprzyjała warunkom psychologicznym człowieka, aby zwiększyć napiwek. Na kolejnej stronie przedstawiono boxploty miesięcy. Na boxplotach nie widać silnych zależności napiwku od miesiąca, a zadanie jest utrudnione tym bardziej, że nie ma danych z wszystkich miesięcy i budując model całoroczny trzeba by było prowadzić ekstrapolację.


Mimo mało widocznych przesłanek, zauważono, że wysokość napiwku jest niższa w marcu i kwietniu i stworzono zmienną dychotomiczną **is_summer**, która przyjmowała wartość 1 dla miesięcy od 5 do 9, a zero dla pozostałych, a jej użyteczność zostanie oceniona po modelowaniu.



Następnie przeanalizowano boxploty dnia tygodnia. Zauważono niżej leżące kwartyle Q1 – Q3 w dniach 0 – 2 i stworzono zmienną dychotomiczną **is_weekday_3_6**.



Na kolejnym wykresie przedstawiono scatterplot napiwku od godziny **time**. Postanowiono podzielić tę zmienną na trzy – zamówienia składane w godzinach porannych i popołudniowych **6 – 16** otrzymywały mniejszy napiwek, niż te po godzinach pracy w godzinach **16 – 21**. Zamówienia składane nocą wiązały się z lekko niższym napiwkiem.



```
106 train <- train %>%
107   mutate(time_of_day = case_when(
108     hour >= 21 | hour < 5 ~ "night",
109     hour >= 5 & hour < 16 ~ "afternoon",
110     hour >= 16 & hour < 21 ~ "evening"
111   ) %>% factor())
```

Wykonano też transformację ciągłą zmiennej **time** na **time_cos**, tak aby jej wartość najwyższa wypadała w czasie wieczornego nasilenia napiwków:

```
113 peak_hour <- 20
114
115 train <- train %>%
116   mutate(time_cos = cos(2 * pi * (time - peak_hour) / 24))
117
118 #####
```

Po wykonaniu powyższych transformacji i dodaniu nowych zmiennych również na zbiorach walidacyjnym i testowym przystąpiono do modelowania.

Modelowanie

W fazie modelowania, jako główne narzędzie, wybrano wielokrotną regresję liniową. Ma ona dwie szczególnie ważne zalety dla tego projektu. Po pierwsze, pozwala ona na bezpośrednią i przejrzystą ocenę zależności oraz kierunku wpływu poszczególnych czynników logistycznych, geograficznych i czasowych na hojność klientów. W literaturze taki model nazywa się white box. Po drugie, jest to metoda bardzo popularna, dobrze udokumentowana i prosta matematycznie. Zgodnie z wcześniejszym etapem przygotowania danych, jako zmienną objaśnianą zastosowano zlogarytmowaną wartość napiwku, co zniwelowało silną prawostronną skośność pierwotnego rozkładu.

W celu odnalezienia najbardziej optymalnej specyfikacji matematycznej, zbudowano i porównano trzy warianty modeli:

- ♦ Model Bazowy: Uwzględniający małą liczbę zmiennych ilościowych najbardziej obiecujących współczynników korelacji w ich surowej formie (**distance, duration_min, fare, points, weekday**)
- ♦ Model Rozszerzony: Wzbogacony o wszystkie autorskie transformacje nieliniowe, zmienne dychotomiczne oraz efekty interakcji zaproponowane w etapie eksploracji danych (**log_distance, dist_dur, log_points, speed, poin_deli, deliveries_f, is_summer, is_weekday_3_6, time_of_day, time_cos**).
- ♦ Model po selekcji krokowej: Powstały w wyniku metody prób i błędów i selekcji wstecznej. Usuwano kolejne zmienne z Modelu Rozszerzonego, kierując się wskaźnikami, przede wszystkim R^2_{adj} . Odrzucono zmienne nieistotne statystycznie, pozostawiając jedynie te o realnej sile predykcyjnej. To zabezpieczyło model przed zjawiskiem nadmiernego dopasowania i ograniczyło liczbę zmiennych, a co za tym idzie liczbę danych potrzebnych do modelowania.


W toku procedury krokowej z modelu usunięte zostały zmienne: **dist_dur, speed, poin_deli, duration_min** oraz **weekday**. Okazało się, że informacja w nich zawarta została lepiej skondensowana (z mniejszą autokorelacją), w nowo utworzonych zmiennych transformowanych, albo nie wносиły one istotnej informacji do modelu. Poniżej wklejono kod w R, wykorzystywany do obliczenia równania regresji wielokrotnej:

```
|  
# --- Model 1: Bazowy (tylko podstawowe zmienne) ---  
model_base <- lm(log_tip ~ distance + duration_min + fare + points + speed + weekday, data = train)  
print("=== PODSUMOWANIE MODELU BAZOWEGO ===")  
print(summary(model_base))
```



Diagnostyka założeń regresji

Przed przystąpieniem do predykcji, zweryfikowano klasyczne założenia metody najmniejszych kwadratów (MNK) dla ostatecznego modelu po selekcji krokowej:

- ♦ **Współliniowość (VIF):** Ponieważ występowały zmienne w postaci czynników, skorzystano z uogólnienia GVIF. Analiza wskaźnika GVIF dla modelu rozszerzonego wykazała bardzo wysokie wartości dla zmiennych **duration_min** ($VIF \approx 15.6$) oraz **dist_dur** ($VIF \approx 28.6$). Obie zmienne próbują w podobny sposób opisać czas dojazdu, ale nie wykorzystano ich w modelu ostatecznym, więc problem został zlikwidowany. W modelu końcowym wzajemne korelacje były niskie:



- ♦ **Homoskedastyczność reszt:** Wykres reszt pokazuje, że wariancja reszt trochę się zmniejsza wraz ze wzrostem zmiennej objaśnianej. Przeprowadzono natomiast test Breuscha-Pagana, który odrzucił hipotezę o stałości wariancji reszt. Występowanie heteroskedastyczności jest zjawiskiem powszechnym przy modelowaniu danych przekrojowych dotyczących zachowań ludzkich – gdy napiwek jest większy, okazuje się, że model z lepszą dokładnością (mniejszą wariancją) przewiduje wynik.
- ♦ **Normalny rozkład reszt:** Wykres Q-Q Plot pokazuje, że nie ma dużych ogonów, tylko małe odchylenia, i rozkład reszt jest w przybliżeniu normalny. To założenie jest spełnione.



Walidacja modelu

Zgodnie z metodologią podziału danych, oceny jakości predykcyjnej dokonano przy użyciu niezależnego zbioru walidacyjnego (15% całkowitej liczby obserwacji). Modele estymowane na próbie treningowej zostały uruchomione na danych walidacyjnych, a uzyskane miary błędu prognozy (RMSE i MAE) przeliczono z powrotem z formy logarytmicznej na oryginalną skalę wyrażoną w dolarach amerykańskich.

	R^2	RMSE	MAE
Model bazowy	0,116	4,792	3,059
Model Rozszerzony	0,261	4,288	2,771
Model po selekcji	0,260	4,265	2,748

Analiza porównawcza jednoznacznie wskazuje, że autorskie transformacje i zmienne dychotomiczne zaimplementowane w Modelu Rozszerzonym pozwoliły na znaczną poprawę jakości dopasowania (wzrost R^2 z 23,1% do 25,2%) oraz spadek błędów prognozy w porównaniu do surowego Modelu Bazowego.

Model po selekcji krokowej, mimo usunięcia kilku zmiennych, zachował praktycznie identyczną zdolność predykcyjną, a nawet zmniejszył lekko średni błąd kwadratowy i średnie odchylenie, będąc jednocześnie modelem prostszym obliczeniowo i bardziej odpornym na przeuczenie.

Generalizacja – Wynik na zbiorze testowym

W celu wykonania ostatecznego sprawdzianu generalizacji wiedzy, model po selekcji krokowej uruchomiono na zbiorze testowym. Uzyskano następujące wskaźniki:

- ♦ $R^2 = 0,2606$
- ♦ RMSE: 4,5536
- ♦ MAE: 2,8749

Niezwykle mała rozbieżność błędów pomiędzy zbiorem walidacyjnym a testowym (wzrost MAE o zaledwie 0,1) dowodzi o stabilności matematycznej modelu i potwierdza, że proces uczenia nie doprowadził do przeuczenia.

Wnioski i interpretacja wyników

Osiągnięty współczynnik determinacji $R^2 = 0,226$ oznacza, że zbudowany model oparty wyłącznie na logistycznych i czasowo-przestrzennych parametrach platformy Uber Eats jest w stanie wyjaśnić 26% całkowitej zmienności wysokości napiwków w Santa Barbara.

Nawiązując bezpośrednio do założeń biznesowych zdefiniowanych na początku projektu wynik ten należy uznać za sukces. Decyzja klienta o przyznaniu konkretnej kwoty napiwku zależy w przeważającej mierze od ulotnych czynników psychologicznych, interpersonalnych i losowych (np. kultura osobista kuriera, stopień

nagrzania posiłku, aktualny nastrój czy profil zamożności klienta), których baza danych z przyczyn oczywistych nie rejestruje. Wykazanie, że czysta charakterystyka techniczna dostawy (odległość, czas, koszty) odpowiada za ponad jedną czwartą decyzji finansowej konsumenta, jest zadowalającym wnioskiem.

Średni błąd absolutny (MAE) na poziomie 2,87\$ oznacza, że prognoza modelu myli się średnio o zaledwie 2,87 dolarów. Z punktu widzenia managera operacyjnego lub dostawcy, pozwala to na symulowanie realnych, całkowitych przychodów kurierów w ujęciu dobowym lub tygodniowym, albo szacowania dodatkowego zarobku na koniec dnia.

Analizując ostateczne współczynniki modelu po selekcji krokowej, zidentyfikowano kluczowe zmienne wpływające na wysokość napiwków:

- ♦ Opłata bazowa (**fare**): Współczynnik ujemny $\beta = -0,028$. Wzrost kosztu samej dostawy przekłada się bezpośrednio na niższy napiwek. Klienci stosują regułę odwrotnie proporcjonalną – droższe zamówienie generuje niższą gratyfikację dla kuriera.
- ♦ Geograficzny dystans **log_distance**: Zmienna **log_distance** posiada dodatni współczynnik, $\beta = 0.04$. Długie, i czasochłonne dostawy na obrzeża Santa Barbara wywołują u klientów, jak się okazuje, większą empatię i skutkują wyższymi napiwkami.
- ♦ Pora dnia (**time_of_day**): Jako kategorię odniesienia (bazową) przyjęto rano i okolice południa. Model wykazał, że dostawy realizowane wieczorem ($\beta = 0.12$) oraz nocą ($\beta = 0.14$) wiążą się ze statystycznie wyższymi napiwkami. Potwierdza to hipotezę o większej hojności konsumentów po godzinach pracy oraz w trakcie spotkań towarzyskich wieczorem i w nocy.
- ♦ Dni tygodnia (**is_weekday_3_6**): Zgodnie z obserwacjami z boxplotów, zamówienia składane od środy do soboty cieszą się statystycznie wyższymi napiwkami ($\beta = 0.09$) w stosunku do początku tygodnia (niedziela-wtorek), co koresponduje z weekendowym rozluźnieniem budżetowym konsumentów.
- ♦ Liczba zamówień łączonych (**deliveries_f**): Wszystkie poziomy faktora (dostawy podwójne 2, potrójne 3) posiadają dodatnie współczynniki w stosunku do dostawy pojedynczej. Oznacza to, że realizowanie przez kuriera kilku zamówień jednocześnie skutkuje zwiększeniem jednorazowego napiwku.
- ♦ Pora roku (**is_summer**): Wykazano, że napiwek zwiększa się podczas cieplejszych miesięcy z dużym współczynnikiem $\beta = 0.15$.
- ♦ Liczba odwiedzonych punktów na trasie (**log_points**). Okazuje się, że im więcej dostaw w trakcie jednego kursu wykona dostawca, tym większe są jego napiwki.

Podsumowując, stawiając się w roli dostawcy, najlepszą strategią maksymalizacji zysków dla kurierów platformy w Santa Barbara jest realizacja pojedynczych zamówień (unikając zleceń łączonych) w godzinach wieczornych (16:00 - 21:00), ze szczególnym uwzględnieniem drugiej połowy tygodnia (od środy do soboty). Podział danych i inżynieria cech pozwoliły na stworzenie stabilnego modelu regresyjnego o wysokiej wartości poznawczej i biznesowej.