

# **Metody i Modele Eksploracyjnej Analizy Danych**

## **Projekt**

Michał Mikołajczyk, Jakub Misztela

04.22.2026


## Business Understanding

Rybołówstwo jest znaczącą gałęzią gospodarki, występującą na całym świecie, ale bardzo zróżnicowaną pod względem połowu różnych gatunków, różnymi metodami i ograniczeniami prawnymi i środowiskowymi. Niepewność wynikająca z ilości zmiennych jest bolesna dla przedsiębiorstw, współpracujących z nimi przewoźników, hurtowników i sprzedawców, którzy potrzebują wiedzieć, ile zasobów należy ulokować i jakich kosztów się spodziewać, a także dla konsumentów.

W projekcie postawiono za cel znalezienie zależności, które pozwoliłyby oszacować, jak dużo ryb uda się złowić przed wypłynięciem jednostki i zbudowanie modelu predykcyjnego. Podstawowym kryterium sukcesu jest osiągnięcie akceptowalnego błędu predykcji. Model ma jednak swoje ograniczenia, które nie pozwolą ekstrapolować jego przewidywań – modelowany jest obszar jednego wydzielonego obszaru na północnym Atlantyku, na podstawie połowów ryb z rzędu *Gadiformes* (Dorszokształtne) w latach 2002-2019. Model nie uwzględnia też wpływu ważnych czynników, jak prawo, połów nielegalny i zanieczyszczenie środowiska.

## Data Understanding

Do modelowania wykorzystano bazę **Fishing Data North Atlantic** <https://www.kaggle.com/datasets/alexanderbader/fishing-data-north-atlantic> z serwisu Kaggle. Jest to bardzo duży zbiór danych – 404544 obserwacji zebranych z zasobów Fiskeridirektoratet dotyczących danych połowów <https://www.fiskeridir.no/statistikk-tall-og-analyse/data-og-statistikk-om-yrkesfiske/apne-data-fangstdata-seddel-koblet-med-fartoydata> i danych zdefiniowanych obszarów połowu <https://opendatafiskeridirektoratet-testkommune.hub.arcgis.com/datasets/lokasjonert-o-m-2017/explore>. Podsumowanie danych pokazuje, że w ponad połowie obszarów nie zanotowano żadnego połowu:



W celu uproszczenia modelu postanowiono modelować tylko wybrane obszary na północ od Norwegii na granicy Morza Norweskiego i Morza Barentsa (rastry 12.07, 12.08, 12.09).

Poszczególne obserwacje reprezentują połów jednej jednostki. Poniżej przedstawiono zmienne występujące w bazie danych:

➤ **Dotyczące jednostki**

- ♦ **ID** – numer identyfikacyjny jednostki,
- ♦ **engine\_age** – wiek silnika jednostki w latach,
- ♦ **length** – długość jednostki w metrach,
- ♦ **power** – moc silnika jednostki w koniach mechanicznych,

➤ **Warunki czasowe i środowiskowe**

- ♦ **month** – numer miesiąca licząc od stycznia 2002,
- ♦ **y\_month** – numer miesiąca w roku,
- ♦ **rok** – numer roku licząc od 2002,
- ♦ **nao\_index** – North Atlantic Oscillator, zmienna ilościowa wyrażająca różnicę ciśnień atmosferycznych nad Azorami i nad Islandią. Tego typu zmienna jest używana w meteorologii do przewidywania burz, co ma wpływ na powodzenie połowu i zachowanie ryb,
- ♦ **surf\_temp** – temperatura powierzchni wody,

➤ **Geograficzne**

- ♦ **landing** - port wyładunku,
- ♦ **patch** – obszar, na który skierowała się jednostka. Obszary zdefiniowane są w danych Fiskeridirektoratet,
- ♦ **patch\_area** – obszar patcha,
- ♦ **dist** – odległość patcha od brzegu w środkowej Norwegii,

➤ **Dotyczące połowu**

- ♦ **y** – zmienna dychotomiczna: 0 – brak połowu, 1 – wystąpił połów,
- ♦ **weight** – masa ryb w kilogramach,
- ♦ **price** – cena ryb za kilogram,
- ♦ **value** – całkowita wartość połowu,
- ♦ **value\_cpi** – wartość połowu z uwzględnieniem inflacji,

## ➤ Czasowe

- ♦ **weighth\_lym** – masa złowionych ryb rok temu,
- ♦ **weighth\_lm** – masa złowionych ryb miesiąc temu,
- ♦ **val\_lym** – wartość połowu rok temu,
- ♦ **val\_lm** – wartość połowu miesiąc temu,

Za zmienną objaśnianą wzięto masę złowionych ryb **weighth**. Przyjęcie za zmienną objaśnianą **value** lub **value\_cpi** komplikowałoby model o zależności trudne do modelowania takie jak gatunek złowionych ryb, inflacja i inne czynniki handlowe jak subsydia, podatki, koszty rozładunku i umowy handlowe.

Nie korzystano ze zmiennych czasowych. Duża część obserwacji nie miała tych wartości, ponieważ nie prowadziła wcześniej połowów, a więc trzeba by było pominąć dużą część obserwacji lub zastosować imputację zmiennych na szeroką skalę.

Do wyznaczania równań regresji nie wykorzystano też zmiennych geograficznych. Zależność między powodzeniem połowu i położeniem geograficznym jest bardzo skomplikowana, zależna od trudno modelowanych czynników takich jak temperatura, prądy morskie, siedliska ryb i wielu innych i jest z pewnością nieliniowa. Zamiast tego, postanowiono skupić się na połowach na niewielkim obszarze geograficznym opisanym patchami xx.xx – xx.xx.

Do kolejnych analiz korzystano tylko z obserwacji z wybranych patchy, w których był połów ( $y = 1$ ). Otrzymano 876 rekordów.