

Metody i Modele Eksploracyjnej Analizy Danych

Projekt

Michał Mikołajczyk, Jakub Misztela

15.05.2026

Business Understanding

W projekcie zajęto się problemem wysokości napiwków otrzymywanych przez dostawców jedzenia. Napiwek jest w tym sensie ciekawym problemem, że można by spodziewać się, że nie będzie łatwo dokonać jego predykcji na podstawie modelu statystycznego, spodziewając się, że zależy to głównie od czynników psychologicznych i charakteru zarówno kuriera, jak i klienta. Postanowiono więc zobaczyć, jak dużo można jednak zamodelować.

W projekcie postawiono za cel znalezienie zależności, od których zależy wysokość napiwku i zbudowanie modelu predykcyjnego. Podstawowym kryterium sukcesu jest osiągnięcie akceptowalnego błędu predykcji. Co ważne, postanowiono nie uwzględniać sytuacji, w których nie było napiwku. Decyzja klienta, czy przyznać napiwek, rządzi się innymi zależnościami niż ustalenie wysokości napiwku. Model ma swoje ograniczenia, które nie pozwolą dowolnie ekstrapolować jego przewidywań – modelowany jest obszar miasta Santa Barbara w Stanach Zjednoczonych, na podstawie danych z aplikacji Uber Eats. Nie uwzględniono ważnych czynników, jak rodzaj i typ restauracji, pogoda czy sytuacja ekonomiczna.

Data Understanding

Do modelowania wykorzystano bazę **Uber Delivery Tips Dataset** <https://www.kaggle.com/datasets/green7ea/uber-delivery-tips-dataset-real-world-data> z serwisu Kaggle. Jest to średniej wielkości zbiór danych – 1214 obserwacji. Po usunięciu obserwacji z zerowym napiwkiem zostało ich 1146. Dane były zbierane od marca do października roku 2025.

Poszczególne obserwacje reprezentują jedną dostawę. Baza nie ma brakujących danych, ale usunięto niektóre zmienne, a poniżej przedstawiono pozostawione:

➤ Zmienna objaśniana

- ♦ **tip** – wysokość napiwku,

➤ Data

- ♦ **date** – data w formacie YYYY-MM-DD,
- ♦ **time** – godzina dostawy, z przedziału [0; 23,5],
- ♦ **weekday** – dzień tygodnia, z przedziału [0; 6],

➤ Zmienne geograficzne

- ♦ **distance** - odległość restauracji od adresu dostawy, w milach,
- ♦ **dropoff_longitude, dropoff_latitude** – współrzędne adresu dostawy,
- ♦ **restaurant_longitude, restaurant_latitude** – współrzędne restauracji,

➤ Dotyczące dostawy

- ♦ **duration_min** – czas dostawy w minutach,
- ♦ **points** – liczba punktów, które odwiedza dostawca na trasie,
- ♦ **deliveries_count** – liczba zamówień w danym adresie,
- ♦ **fare** – koszt dostawy.

Data Preparation

Postanowiono wykonać transformacje kilku zmiennych, aby poszukać ukrytych informacji:

- ♦ **month** – miesiąc roku, z przedziału [0; 11]. Choć dane nie były zbierane we wszystkich miesiącach, można się spodziewać zależności, że wraz z corocznymi wahaniami temperatury wysokość napiwka będzie się zmieniać,
- ♦ **time_sin, time_cos** – godzina znormalizowana i przedstawiona we współrzędnych kątowych, według wzoru:

wzorek

- ♦ **###weekday_sin, weekday_cos**
- ♦ **geo_distance** – odległość między restauracją a adresem dostawy. Nie jest to zmienna tożsama z **distance**, ponieważ jedna to odległość bezwzględna, a druga to droga zrobiona przez dostawcę.

screen z R albo wzorek

- ♦ **speed** – $\text{distance} / \text{duration_min}$
- ♦ **geo_speed** – $\text{geo_distance} / \text{duration_min}$

W tak przygotowanej bazie najpierw zrobiono korelogram zmiennej objaśnianej z **distance**, **geo_distance**, **duration_min**, **fare** i **speed**, ponieważ spodziewano się tam zależności liniowych: