

Metody i Modele Eksploracyjnej Analizy Danych

Projekt

Michał Mikołajczyk, Jakub Misztela

15.05.2026

Business Understanding

W projekcie zajęto się problemem wysokości napiwków otrzymywanych przez dostawców jedzenia. Napiwek jest w tym sensie ciekawym problemem, że można by spodziewać się, że nie będzie łatwo dokonać jego predykcji na podstawie modelu statystycznego, spodziewając się, że zależy to głównie od czynników psychologicznych i charakteru zarówno kuriera, jak i klienta. Postanowiono więc zobaczyć, jak dużo można jednak zamodelować.

W projekcie postawiono za cel znalezienie zależności, od których zależy wysokość napiwku i zbudowanie modelu predykcyjnego. Podstawowym kryterium sukcesu jest osiągnięcie akceptowalnego błędu predykcji. Co ważne, postanowiono nie uwzględniać sytuacji, w których nie było napiwku. Decyzja klienta, czy przyznać napiwek, rządzi się innymi zależnościami niż ustalenie wysokości napiwku. Model ma swoje ograniczenia, które nie pozwolą dowolnie ekstrapolować jego przewidywań – modelowany jest obszar miasta Santa Barbara w Stanach Zjednoczonych, na podstawie danych z aplikacji Uber Eats. Nie uwzględniono ważnych czynników, jak rodzaj i typ restauracji, pogoda czy sytuacja ekonomiczna.

Data Understanding

Do modelowania wykorzystano bazę **Uber Delivery Tips Dataset** <https://www.kaggle.com/datasets/green7ea/uber-delivery-tips-dataset-real-world-data> z serwisu Kaggle. Jest to średniej wielkości zbiór danych – 1214 obserwacji. Po usunięciu obserwacji z zerowym napiwkiem zostało ich 1146. Dane były zbierane od marca do października roku 2025.

Poszczególne obserwacje reprezentują jedną dostawę. Baza nie ma brakujących danych, ale usunięto niektóre zmienne, a poniżej przedstawiono pozostawione:

➤ Zmienna objaśniana

- ♦ **tip** – wysokość napiwku,

➤ Data

- ♦ **date** – data w formacie YYYY-MM-DD,
- ♦ **time** – godzina dostawy, z przedziału [0; 23,5],
- ♦ **weekday** – dzień tygodnia, z przedziału [0; 6],

➤ Zmienne geograficzne

- ♦ **distance** - odległość restauracji od adresu dostawy, w milach,
- ♦ **dropoff_longitude, dropoff_latitude** – współrzędne adresu dostawy,
- ♦ **restaurant_longitude, restaurant_latitude** – współrzędne restauracji,

➤ Dotyczące dostawy

- ♦ **duration_min** – czas dostawy w minutach,
- ♦ **points** – liczba punktów, które odwiedza dostawca na trasie,
- ♦ **deliveries_count** – liczba zamówień w danym adresie,
- ♦ **fare** – koszt dostawy.

Data Preparation

Nie wykonywano normalizacji, bo nie jest ona potrzebna przy regresji wielokrotnej. Postanowiono wykonać transformacje kilku zmiennych, aby poszukać ukrytych informacji:

- ♦ **month** – miesiąc roku, z przedziału [0; 11]. Choć dane nie były zbierane we wszystkich miesiącach, można się spodziewać zależności, że wraz z corocznymi wahaniami temperatury wysokość napiwka będzie się zmieniać,
- ♦ **geo_distance** – odległość między restauracją a adresem dostawy. Nie jest to zmienna tożsama z **distance**, ponieważ jedna to odległość bezwzględna, a druga to droga zrobiona przez dostawcę.

screen z R albo wzorek

- ♦ **speed** – $\text{distance} / \text{duration_min}$
- ♦ **geo_speed** – $\text{geo_distance} / \text{duration_min}$


W tak przygotowanej bazie najpierw postanowiono najpierw zrobić korelogram zmiennej objaśnianej z **distance**, **geo_distance**, **duration_min**, **fare**, **geo_spped** i **speed**, ponieważ spodziewano się tam zależności liniowych.

Podczas przeglądania korelogramu natrafiono na outlier w zmiennej **geo_distance**. Po analizie okazało się, że pochodzi on z odstającej wartości w **dropoff_latitude**. Najprawdopodobniej była to literówka osoby tworzącej bazę danych, bo wartość różniła się o stopień od wartości tej zmiennej dla innych obserwacji. Zaimputowaną więc do bazy danych powiększoną o stopień zmienną. Sytuację tę przedstawiono na box plot na kolejnej stronie:


Histogramy zmiennych wskazują, że wszystkie z nich są prawoskośne. Przez to, że nie są to rozkłady liniowe, nie można ufać testowi p-value. Spróbowano zlogarytmować zmienne, ale dało to efekt w postaci bardziej zbliżonego do normalnego rozkładu tylko w przypadku **log_tip** i **log_distance**. Rozkład **log_geo_distance** otrzymał dwa wierzchołki, a jego korelacja ze zmienną objaśnianą zmniejszyła się. Rozkład pozostałych zmiennych nie poprawił się, a ich korelacje pozostały słabe.

Ogólnie, korelacje zmiennych objaśniających i objaśnianej **tip** są słabe. Najmocniejsza jest **duration_min** i skorelowane ze sobą odległości **distance** i **geo_distance**. Wskazuje to na to, że odbiorcy nie uwzględniają zwykle kosztu dostawy i prędkości, z jaką jechał dostawca w ustaleniu wysokości napiwku. Fakt, że **geo_distance** ma słabszą korelację niż odległość, jaką przebył dostawca może sugerować, że odbiorcy znają czas dojazdu do restauracji, z której zamawiają jedzenie i nie posługują się miarą geograficzną, która nie oddaje czasu i drogi potrzebnej aby do niej dojechać. Podobna sytuacja występuje z **geo_speed**.


W celu ograniczenia liczby zmiennych i przedziwziałaniu dużej korelacji w objaśniających **log_distance** i **duration_min** wprowadzono nową zmienną **dist_dur** jako iloczyn tych dwóch i okazało się, że jej korelacja jest odrobinę lepsza – więc zostawiono ją do testów.




Pozostałe zmienne, jak widać po korelogramie nie mają żadnego widocznego wpływu na zmienną objaśnianą:



Zmienna **deliveries_count** przyjmowała trzy wartości, więc zastosowano one-hot encoding, zmieniając typ danej na faktor. Uznano, że różnica pomiędzy jednym, a dwoma zamówieniami może być inna, niż różnica między dwoma a trzema:




Zrobiono także dodatkowy korelogram korelacji Spearmana, chcąc oszacować zależności między zmiennymi, które nie mają rozkładów normalnych:




Zobaczywszy, że istnieje pewna korelacja między **points** a **deliveries_count** dodano nową zmienną **poin_deli** jako iloczyn tych dwóch. Z korelogramu Można wywnioskować, że często występuje korelacja między wysokością napiwku, a liczbą zamówień, a także, że występuje dość duża korelacja między liczbą zamówień pod jednym adresem, a całkowitą liczbą adresów, jakie odwiedza dostawca **points**. W trakcie modelowania ocenione będą różne kombinacje tych zmiennych na zbiorze walidacyjnym.

Jako ostatnie przeanalizowano zmienne związane z czasem. Można się spodziewać, że napiwek będzie większy, gdy pora dnia i roku będzie sprzyjała warunkom psychologicznym człowieka, aby zwiększyć napiwek. Na kolejnej stronie przedstawiono boxploty miesięcy. Na boxplotach nie widać silnych zależności napiwku od miesiąca, a zadanie jest utrudnione tym bardziej, że nie ma danych z wszystkich miesięcy i budując model całoroczny trzeba by było prowadzić ekstrapolację.


Mimo mało widocznych przesłanek, zauważono, że wysokość napiwku jest niższa w marcu i kwietniu i stworzono zmienną dychotomiczną **is_summer**, która przyjmowała wartość 1 dla miesięcy od 5 do 9, a zero dla pozostałych, a jej użyteczność zostanie oceniona po modelowaniu.



Następnie przeanalizowano boxploty dnia tygodnia. Zauważono niżej leżące kwartyle Q1 – Q3 w dniach 0 – 2 i stworzono zmienną dychotomiczną **is_weekday_3_6**.



Na kolejnym wykresie przedstawiono scatterplot napiwku od godziny **time**. Postanowiono podzielić tę zmienną na trzy – zamówienia składane w godzinach porannych i popołudniowych **6 – 16** otrzymywały mniejszy napiwek, niż te po godzinach pracy w godzinach **16 – 21**. Zamówienia składane nocą wiązały się z lekko niższym napiwkiem.



```
106 train <- train %>%
107   mutate(time_of_day = case_when(
108     hour >= 21 | hour < 5 ~ "night",
109     hour >= 5 & hour < 16 ~ "afternoon",
110     hour >= 16 & hour < 21 ~ "evening"
111   ) %>% factor())
```

Wykonano też transformację ciągłą zmiennej **time** na **time_cos**, tak aby jej wartość najwyższa wypadała w czasie wieczornego nasilenia napiwków:

```
113 peak_hour <- 20
114
115 train <- train %>%
116   mutate(time_cos = cos(2 * pi * (time - peak_hour) / 24))
117
118 #####
```

Po wykonaniu powyższych transformacji i dodaniu nowych zmiennych również na zbiorach walidacyjnym i testowym przystąpiono do modelowania.

modelowanie